

# **ESCUELA POLITÉCNICA NACIONAL**ESCUELA DE FORMACIÓN DE TECNÓLOGOS



# ANÁLISIS DE DATOS TSDS

**ASIGNATURA**: ANÁLISIS DE DATOS

PROFESOR: Ing. Lorena Chulde / Ing. Juan Pablo Zaldumbide

**FECHA**: 13 – 08 - 2024 **PERÍODO ACADÉMICO**: 2024-A

# **PPROYECTO FINAL – BIMESTRE 2**



# Integrantes:

Jonathan Ramírez Andrés Tufiño Evelyn Guachamin

2024-A

Link de github del proyecto

https://github.com/Andrespipe1/Proyecto Analisis

https://www.youtube.com/watch?v=X2rgjO88Kj8

https://www.youtube.com/watch?v=0iS8tnuOyOE

#### **INFORME**

## **DEFINICIÓN DEL CASO DE ESTUDIO**

Este proyecto se centra en el análisis de datos de diversas fuentes para evaluar y visualizar una amplia gama de temas, como eventos deportivos a nivel mundial, actividades recreativas, conciertos, películas y restaurantes. El objetivo principal es integrar y analizar esta información utilizando herramientas de bases de datos tanto relacionales como NoSQL, y presentar los resultados a través de visualizaciones en Power Bl. En la actualidad, el análisis de datos se ha vuelto una práctica fundamental tanto en el ámbito empresarial como en el personal, ya que permite obtener información valiosa que facilita la toma de decisiones. Un análisis exhaustivo proporciona una visión completa, ayudando a elegir desde la mejor película para ver hasta la estrategia más adecuada para un negocio.

## **OBJETIVO GENERAL**

 Combinar y analizar datos de distintas fuentes para ofrecer una perspectiva completa sobre eventos deportivos, actividades, conciertos, películas y restaurantes, utilizando Power BI para visualizar los resultados de manera sencilla y comprensible.

## **OBJETIVOS ESPECÍFICOS**

- Reunir datos de al menos 10 fuentes diferentes que cubren una variedad de temas, como deportes, conciertos, películas y restaurantes.
- Utilizar dos tipos de bases de datos relacionales y dos bases de datos NoSQL para almacenar y gestionar la información.
- Convertir los datos entre formatos como CSV y JSON para asegurar que se puedan unir y utilizar sin problemas.
- Visualizar todos los datos combinados en Power BI para obtener información clara y útil que ayude a tomar decisiones más informadas.

Descripción del equipo de trabajo y actividades realizadas por cada uno.

## Equipo de trabajo:

El equipo de trabajo consta de los siguientes estudiantes:

Jonathan Ramírez: Coordinador del Proyecto y Encargado de Bases de Datos.

Andrés Tufiño: Especialista en Análisis y Transformación de Datos.

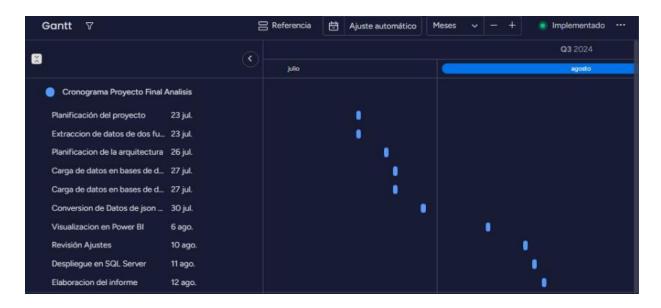
Evelyn Guachamin: Responsable de la Visualización de Datos en Power Bl.

1

#### Actividades realizadas:

- Coordinador del Proyecto: Organiza y supervisa las tareas del equipo, asegurando que todos estén alineados con los objetivos. También se encarga de gestionar las bases de datos, asegurando que la información esté bien almacenada.
- Encargado del Análisis de Datos: Recolecta y limpia los datos, además de convertirlos entre formatos como CSV y JSON para que sean compatibles con las diferentes herramientas que usamos.
- Responsable de Visualización: Crea los gráficos y paneles en Power BI, presentando los datos de manera visual para que sea más fácil entender la información y sacar conclusiones útiles.

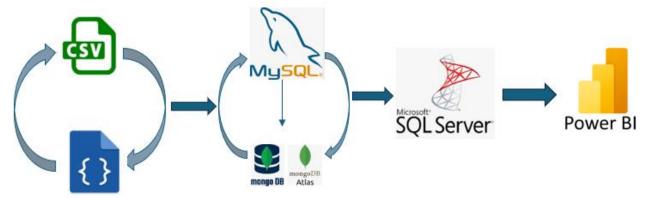
# Cronograma de actividades incluido el diagrama de gantt (project)





# - Recurso y herramientas utilizadas.

- Bases de Datos Relacionales: MySQL- SQL Server
- Bases de Datos NoSQL: MongoDB
- Herramientas de conversión de datos: CSV JSON
- Herramientas de Visualización: Power BI
- Otras Herramientas: Microsoft Project, Microsoft Excel
- Arquitectura de la solución.



- Extracción de datos.

La extracción de los datos se obtuvo de los siguientes links, de acuerdo con la categoría en mención.

# **Evento Deportivos a nivel mundial**

- https://www.kaggle.com/datasets/amirba/olympic-sports-and-medals-18962021
- https://figshare.com/articles/dataset/Olympic history longitudinal data scraped f rom www sports-reference com/6121274

# **Actividades y Hobbies**

- <u>https://www.kaggle.com/datasets/mfrancis23/museum-of-modern-art-collection?select=Artworks.csv</u>
- https://www.kaggle.com/datasets/drahulsingh/largest-art-museums

# **Conciertos y Evento Públicos**

- https://data.world/ben-pfeifer/nirvana-live-performances
- https://www.kaggle.com/datasets/dmytroievdokymov/metallica-concerts-data

3

# Restaurantes y Sitios de Esparcimientos

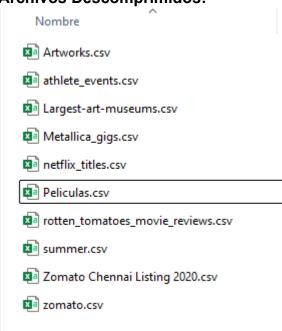
- https://www.kaggle.com/datasets/phiitm/chennai-zomato-restaurants-data
- <u>https://www.kaggle.com/datasets/shrutimehta/zomato-restaurants-</u>data?select=zomato.csv

## **Películas**

- <a href="https://www.kaggle.com/datasets/coltonbarger/rotten-tomatoes-reviews-for-online-streaming-shows">https://www.kaggle.com/datasets/coltonbarger/rotten-tomatoes-reviews-for-online-streaming-shows</a>
- https://www.kaggle.com/datasets/priyamchoksi/rotten-tomato-movie-reviews-1-44m-rows

La descarga se realizó en un archivo zip. Para usar los archivos, primero se descomprime el zip, luego se renombran los datasets y se guardan en una carpeta organizada para facilitar el trabajo con ellos.

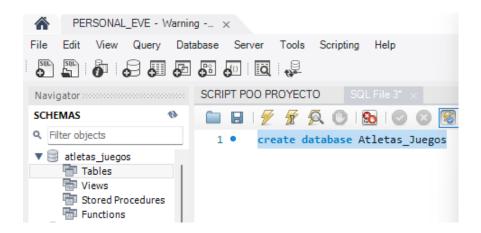
# **Archivos Descomprimidos:**



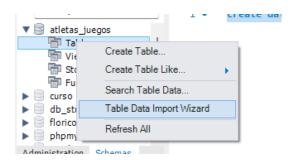
# ANÁLISIS DE INFORMACIÓN.

# Cambio de un archivo CSV a MYSQL

1. Creación de una Base de Datos en el programa MYSQL



2. Dar clic derecho en la opción tables de la base de datos



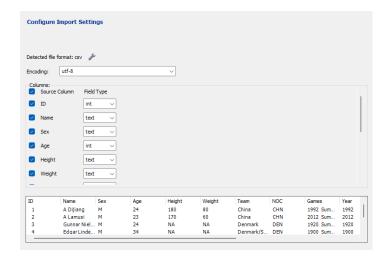
- 3. Seguimos los paso requeridos para importar de un archivo CSV a nuestra base de datos
- Escogemos el archivo



- Elegimos la opción crear una nueva tabla



- Elegimos el formato de nuestra tabla



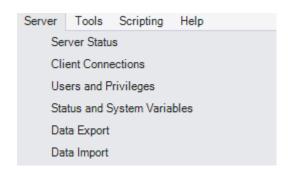
- Importamos la tabla desde nuestro archivo CSV



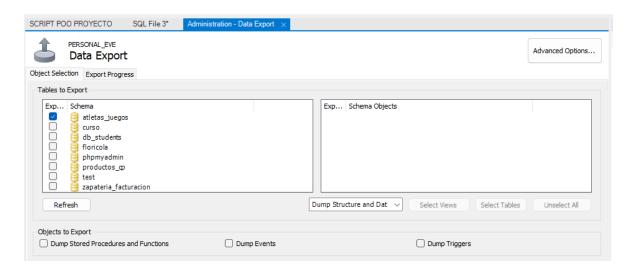
Visualizamos la importación del archivo.

- Export: Wrap Cell Content: 🚻 Fetch rows: Name ID Height Weight Team NOC Games Year Season City E Sex Age Sport NULL A Dijiang 24 180 80 China CHN 1992 Summer Summer Basketball В NULL A Lamusi 23 170 China CHN 2012 Summer Judo 60 Summer London Jι NULL Gunnar Nielsen Aaby Denmark Football 3 24 NA NA DEN 1920 Summer Summer Antwerpen Fi 4 Edgar Lindenau Aabye М 34 NΑ NΑ Denmark/Sweden DFN 1900 Summer Summer Paris Tug-Of-War Τı NULL Christine Jacoba Aaftink Netherlands Speed Skating 1988 Winter Calgary NULL 5 82 NED Speed Skating Christine Jacoba Aaftink 21 185 Netherlands 1988 Winter Winter Calgary Sı NULL Christine Jacoba Aaftink 25 185 82 Netherlands NED 1992 Winter Winter Albertville Speed Skating NULL 5 Christine Jacoba Aaftink 25 185 82 Netherlands NED 1992 Winter Winter Albertville Speed Skating NULL Christine Jacoba Aaftink 27 185 Netherlands NED 1994 Winter Winter Lillehammer Speed Skating NULL Christine Jacoba Aaftink Netherlands 1994 Winter 5 27 185 82 NED Winter Lillehammer Speed Skating NULL 6 Per Knut Aaland 31 188 75 United States USA 1992 Winter Winter Albertville Cross Countr... O NULL 6 Per Knut Aaland М 31 188 75 United States USA 1992 Winter Winter Albertville Cross Countr... C NULL Per Knut Aaland United States 1992 Winter Albertville Cross Countr... C 31 188 75 USA Winter NULL 6 Per Knut Aaland М United States Albertville Cross Countr... O 31 188 75 USA 1992 Winter Winter NULL 6 Per Knut Aaland 33 188 75 United States USA 1994 Winter Winter Lillehammer Cross Countr... O NULL Per Knut Aaland United States USA 1994 Winter Lillehammer Cross Countr... C NULL 6 Per Knut Aaland 188 United States USA 1994 Winter Lillehammer Cross Countr... C 33 Winter

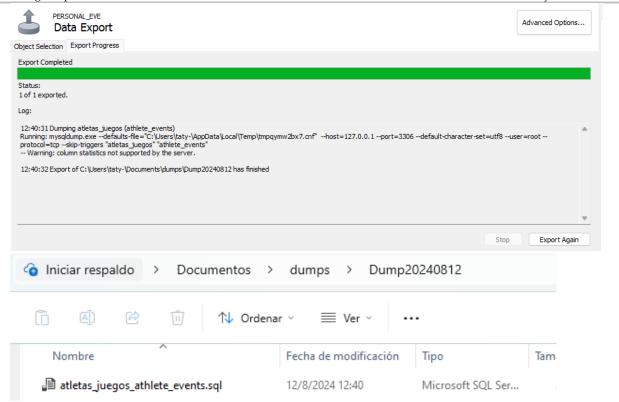
#### MIGRACION DE UN ARCHIVO DE MYSQL A SQL SERVER



- Seleccionamos la base de datos

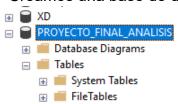


- Exportamos la base de datos en un archivo SQL, el cual se guarda en la carpeta dumps.

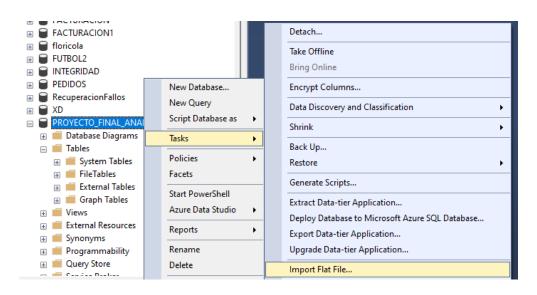


# El archivo descargado abrimos en SQL Server

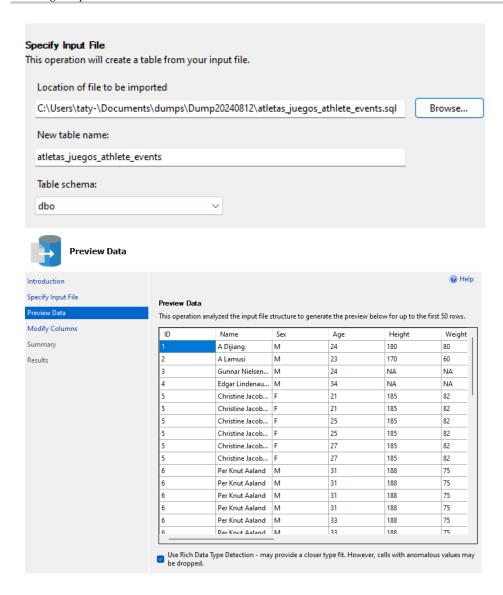
- Creamos una base de datos donde contendrá todas nuestras fuentes de datos



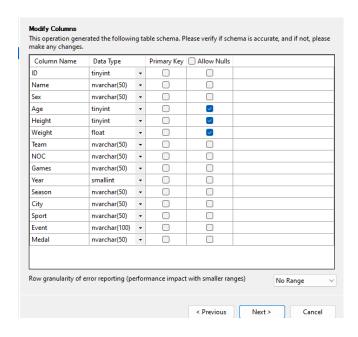
- En la base de datos creada en SQL Server procedemos a importar los archivos SQL.



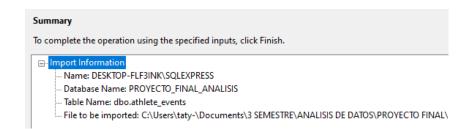
- Seleccionamos el archivo SQL



- Seleccionamos y modificamos los tipos de datos y configuraciones de cada columna.



Verificamos la información.



Verificamos que la data se encuentre en la base de datos que hemo creado.

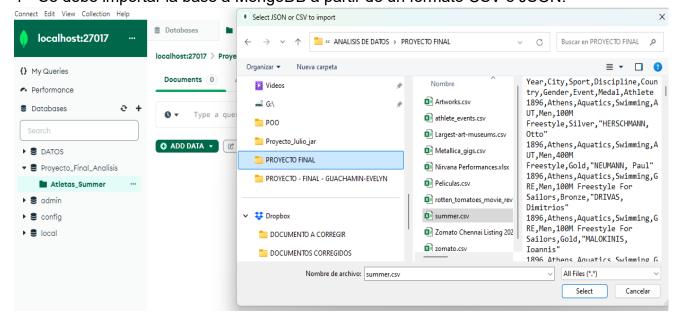


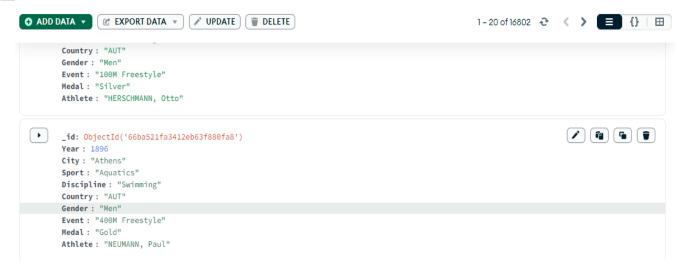
# Conexión desde MongoDB a MYSQL Y SQL SERVER.

La importación o migración de los archivos se puede realizar a partir de un programa. Esta herramienta permite realizar migración desde SQL – MONGODB o viceversa.

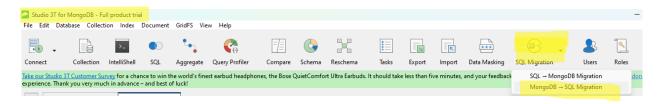
La Herramienta se llama Studio 3T, para utilizarla se realiza los siguientes pasos:

1- Se debe importar la base a MongoDB a partir de un formato CSV o JSON.

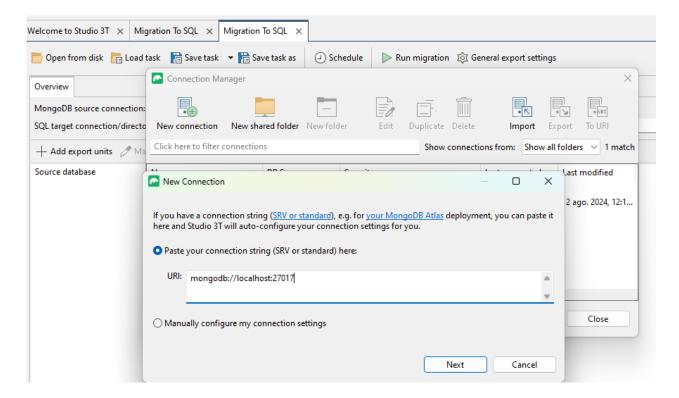




2- Con el programa descargado procedemos a realizar la migración



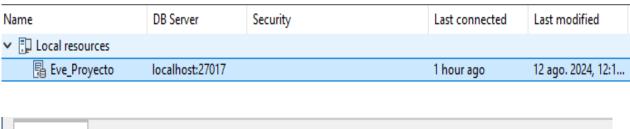
3- Al ser la primera conexión procedemos a guardar la conexión que tendremos con nuestro MongoDB

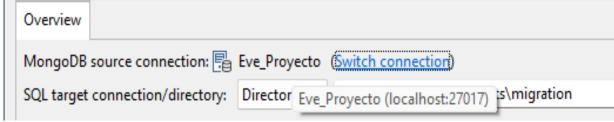


- La Uri encontramos en la página principal de MongoDB

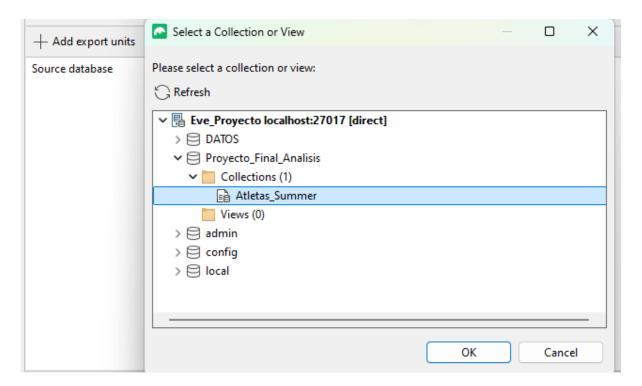


- Agregamos un nombre a la conexión que usaremos

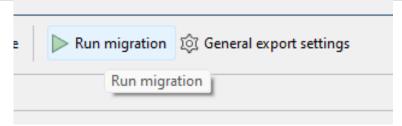




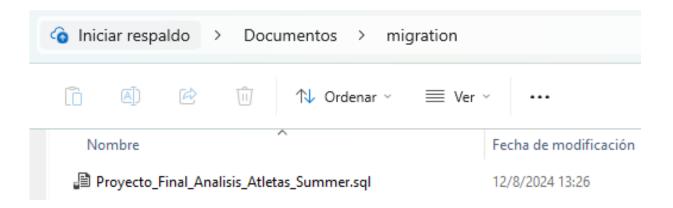
- Añadimos la base de datos y la tabla que requerimos migrar



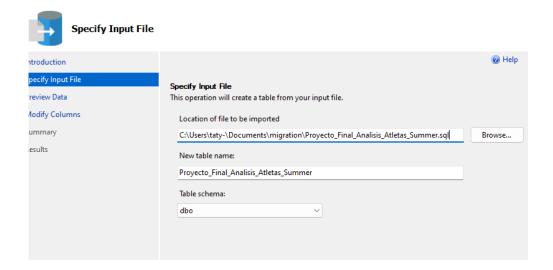
- Colocamos en un directorio nuestra migración y ejecutamos la migración

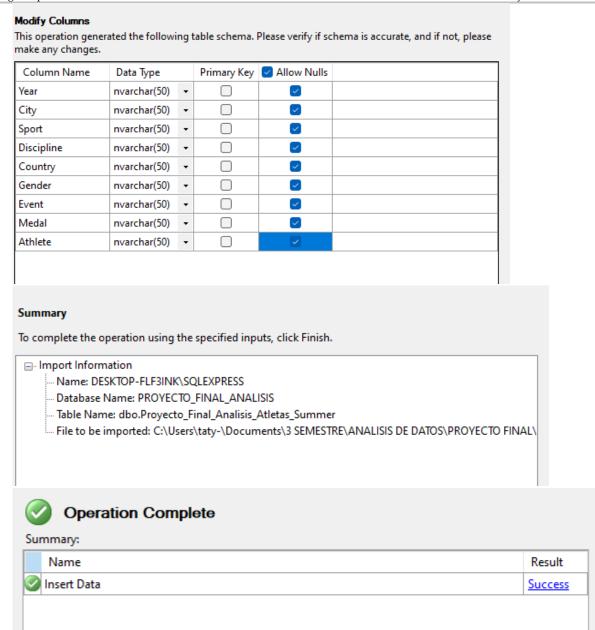


- De esta manera en nuestro directorio ya disponemos nuestro archivo SQL para la importación en SQLSERVER

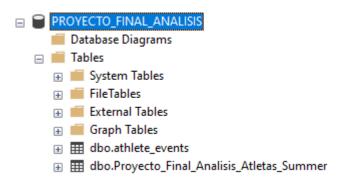


Realizamos las importaciones de nuestras bases de datos en SQL SERVER.

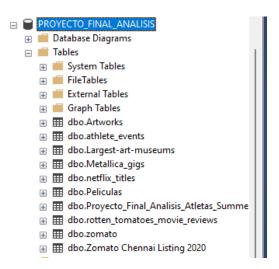




- Al finalizar de realizar la importación procedemos a verificar que la importación se realice de manera correcta.

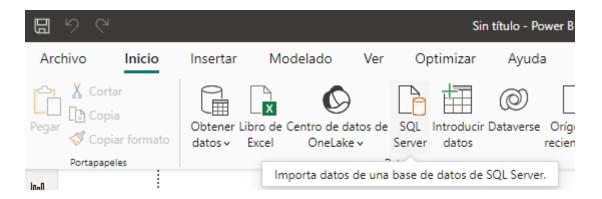


El proceso anterior se realiza para todos los dataset descargados para empezar a trabajar en POWER BI.

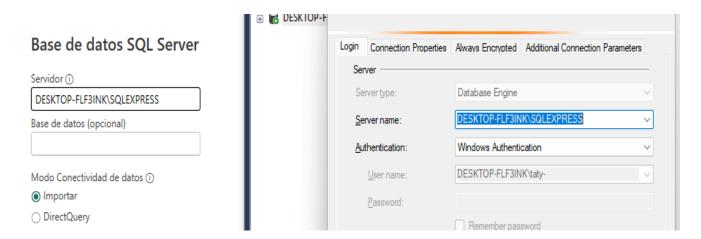


# **CONEXIÓN DE SQL SERVER CON POWER BI**

- En POWER BI procedemos a escoger la opción SQL SERVER para establecer la conexión.

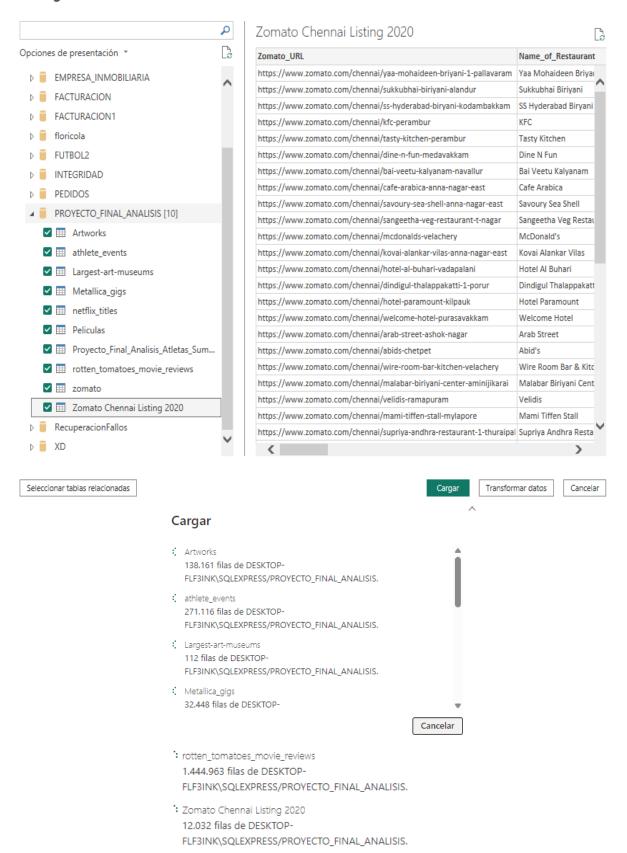


Colocamos el nombre del servidor

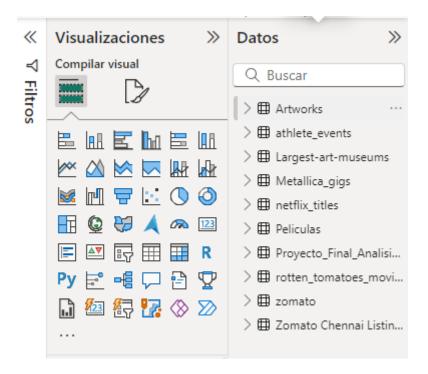


- Con ellos procedemos a aceptar para cargar la información seleccionamos las tablas y subimos la información.

# Navegador

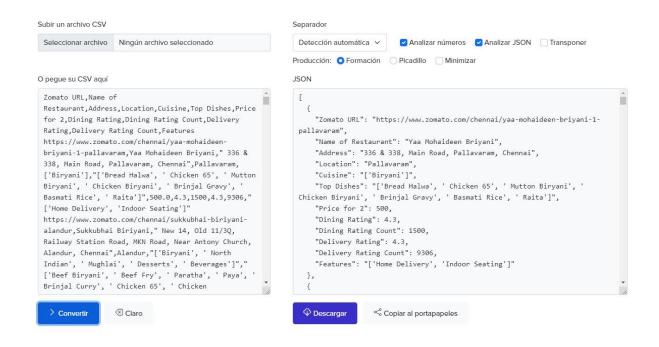


Con la información cargada procedemos a realizar los análisis requeridos

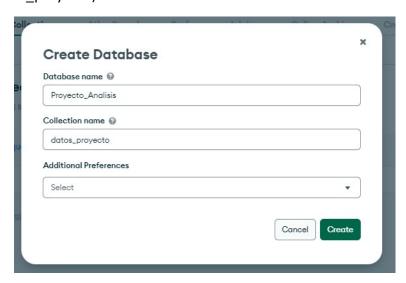


# CONEXIÓN JSON - MONGODB ATLAS - MONGO DB COMPAS - MYSQL - SQL SERVER - POWER BI

1) JSON: Se obtuvo el dataset de KAGGLE, el cual se lo descargo en un formato csv. Posterior a esto se utilizó una pagina online para convertir el archivo csv a un archivo json y así cumplir con la arquitectura planteada.



2) MongoDB Atlas – MongoDB Compas: Se inicio sesión en MongoDB Atlas para después crear un clúster en donde se creó una base de datos (Proyecto\_Análisis) y una colección (datos\_proyecto) en la nube.



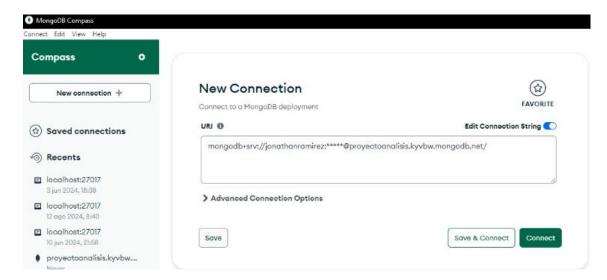
- Luego para hacer una conexión debemos añadir un usuario y contraseña



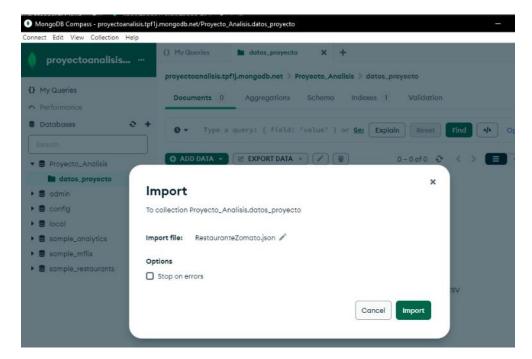
- Y se nos da una url para hacer la respectiva conexión



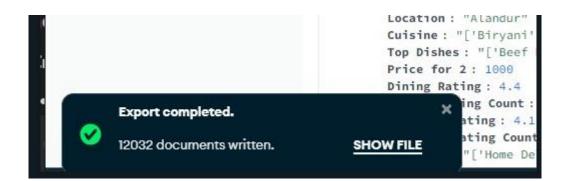
Nos dirigimos al MongoDB Compas



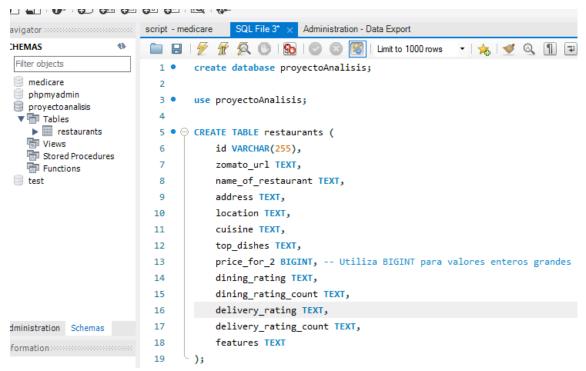
Ya lista la conexión se importa el archivo JSON en la base de datos ya creada



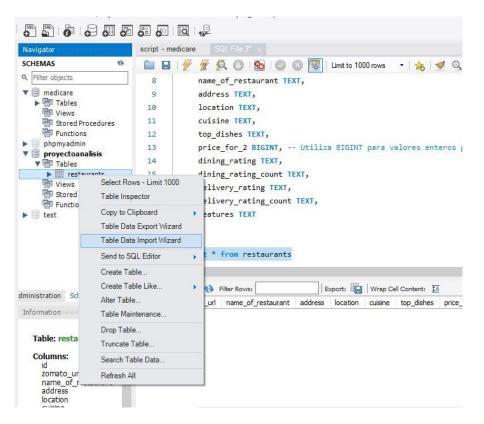
- Finalmente se exporta el archivo JSON en CSV para poder pasarlo a MYSQL

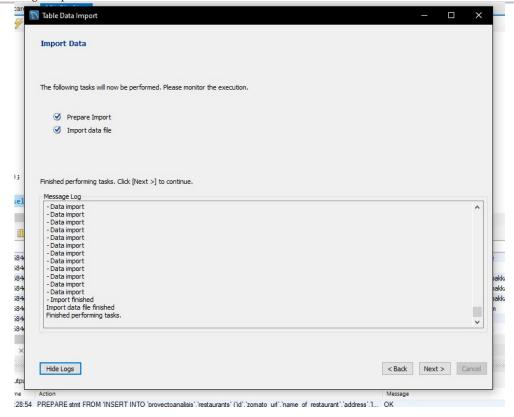


3) MYSQL: Creamos una base de datos y la tabla en donde se van a almacenar los datos del csv.

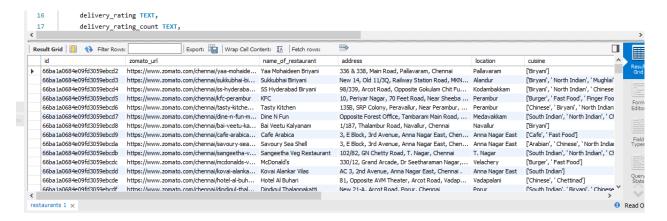


Y exportamos nuestro csv en la tabla correspondiente

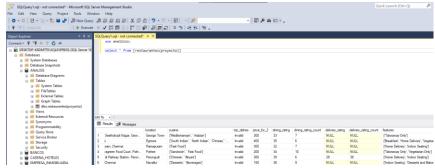




Comprobamos los datos



Y luego exportamos el archivo para poder abrirlo en SQL Server



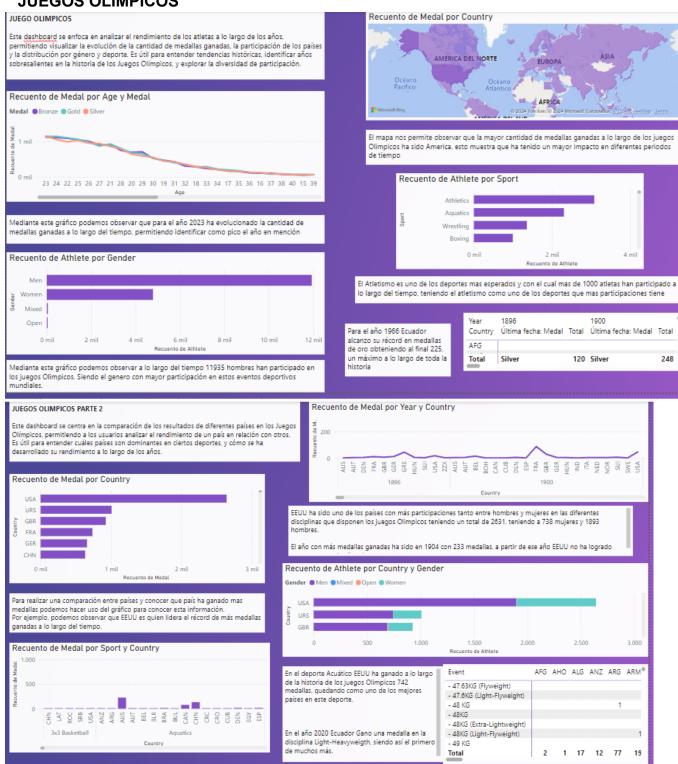
**4)** Se importan los datos en el SQL Server para posteriormente hacer la conexión con el POWER BI

# VISUALIZACIÓN Y RESULTADOS DE LA INFORMACIÓN

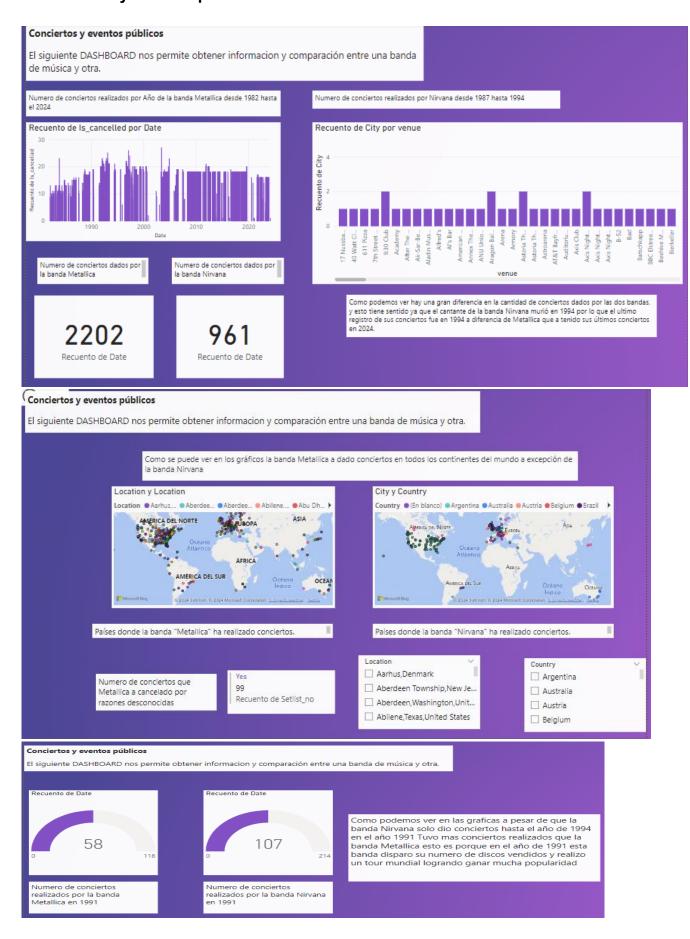
#### Presentación de DASHBOARD Y CONSULTAS realizados en POWER-BI

# - Eventos deportivos a nivel mundial.

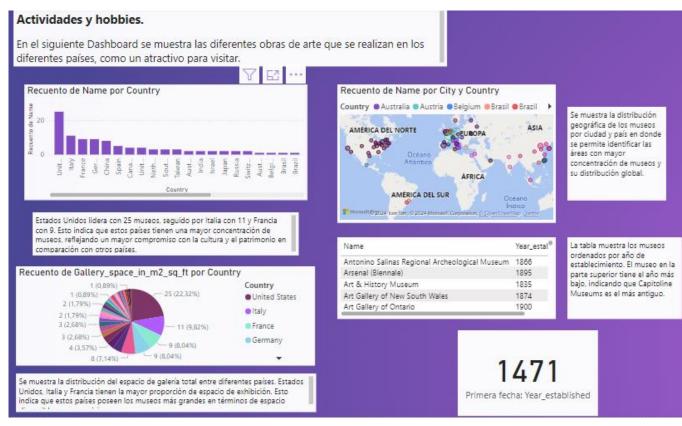
## **JUEGOS OLIMPICOS**

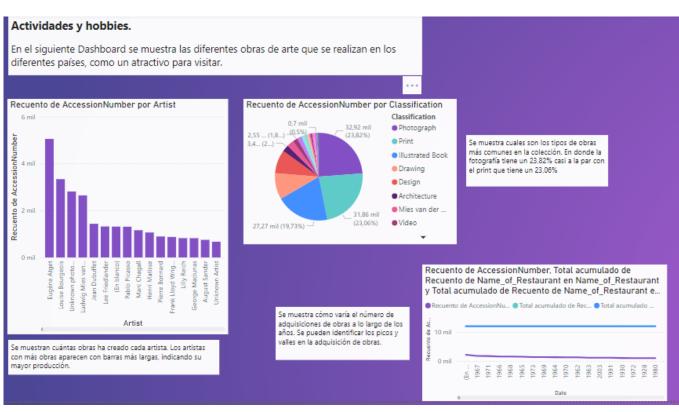


# - Conciertos y eventos públicos.

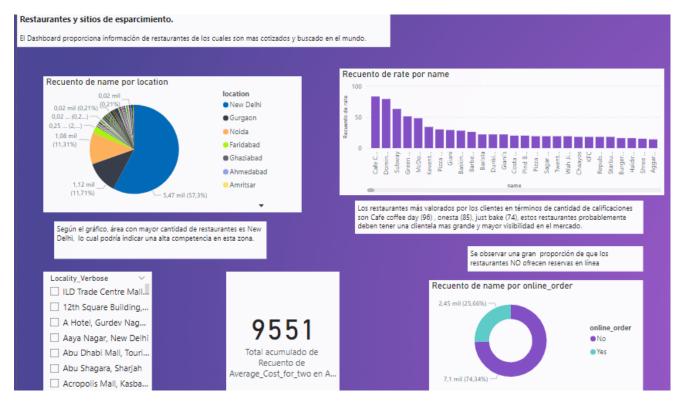


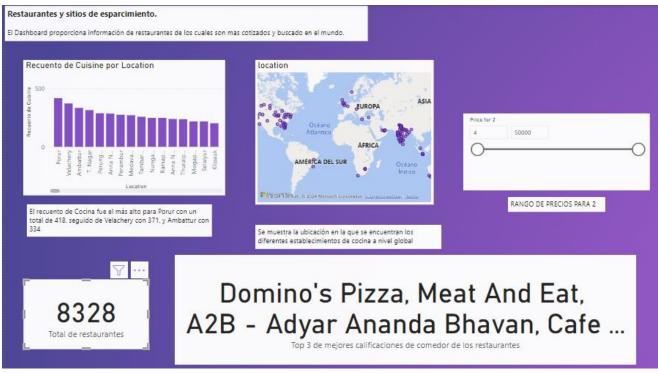
# - Actividades y hobbies.





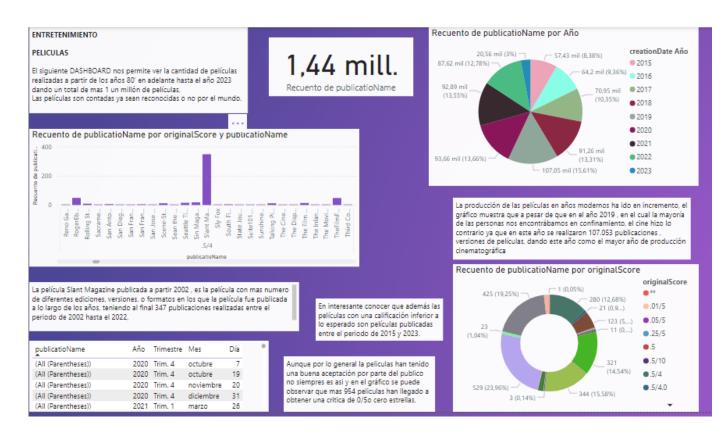
# - Restaurantes y sitios de esparcimiento.





#### Tema Libre:

## **PELICULAS**





## **CONCLUSIONES Y RECOMENDACIONES**

#### 4- Conclusiones:

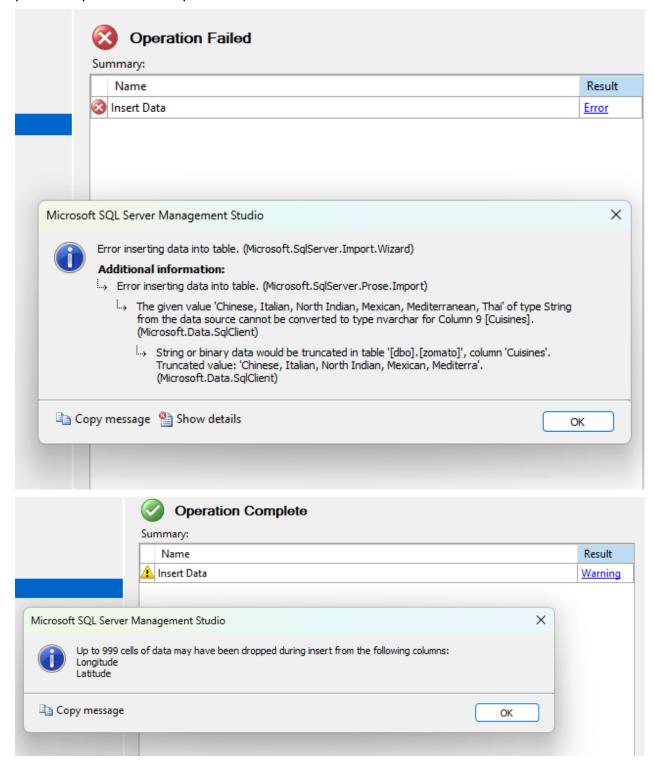
- Es importante buscar data sets que tengan una buena estructura caso contrario se dificultara a la hora de realizar dashboards como nos ocurrió a nosotros.
- Manejar diferentes formatos de datos (JSON, CSV) y estructuras de bases de datos (relacionales y NoSQL) requiere una cuidadosa planificación y herramientas adecuadas si no se realiza correctamente se pierde la integridad de los datos.
- Los dashboards bien diseñados permiten comunicar de manera clara y concisa los resultados del análisis a un público no técnico.

#### - Recomendaciones:

- Un cronograma detallado y realista es esencial para cumplir con los plazos del proyecto.
- La arquitectura de la solución debe ser diseñada cuidadosamente para garantizar la escalabilidad, la flexibilidad y la eficiencia.

# **DESAFÍOS Y PROBLEMAS ENCONTRADOS.**

- **Importación de CSV a SQL Server:** Durante la importación de un archivo CSV a una base de datos en SQL Server, nos enfrentamos a un error que señalaba la necesidad de ajustar los datos de cada campo de acuerdo con la sintaxis de SQL Server. Este inconveniente requirió realizar modificaciones en el formato de los datos para cumplir con los requisitos del sistema.



- **Integración de Dashboards en Power BI:** La tarea de unificar los dashboards previamente desarrollados resultó compleja debido a la ausencia de una opción gratuita en Power BI que permitiera consolidar múltiples archivos en un solo proyecto. Esta limitación complicó el proceso de integración de todos los dashboards en un único archivo de manera efectiva.



# 5- Link de github del proyecto

https://github.com/Andrespipe1/Proyecto Analisis

https://www.youtube.com/watch?v=X2rgjO88Kj8

https://www.youtube.com/watch?v=0iS8tnuOyOE